

Rekonstruksi Objek Irregular Terpendam pada Beton Berbasis Sinyal Ground-Penetrating Radar Menggunakan Generative Adversarial Network

*Note: Sub-titles are not captured in Xplore and should not be used

1 st John Parulian Siahaan Departemen Teknik Komputer Fakultas Teknologi Elektro dan Informatika Cerdas Institut Teknologi Sepuluh Nopember (ITS) Surabaya, Indonesia email address or ORCID	2 nd Given Name Surname dept. name of organization (of Aff.) name of organization (of Aff.) City, Country email address or ORCID	3 rd Given Name Surname dept. name of organization (of Aff.) name of organization (of Aff.) City, Country email address or ORCID
4 th Given Name Surname dept. name of organization (of Aff.) name of organization (of Aff.) City, Country email address or ORCID	5 th Given Name Surname dept. name of organization (of Aff.) name of organization (of Aff.) City, Country email address or ORCID	6 th Given Name Surname dept. name of organization (of Aff.) name of organization (of Aff.) City, Country email address or ORCID

Abstract—Ground Penetrating Radar (GPR) sudah sering digunakan dalam ilmu geofisika untuk mendeteksi objek tertimbun bawah tanah. Tidak hanya pada media tanah, media lain seperti kayu, beton, dan aspal juga dapat digunakan. Objek yang dideteksi juga bisa dalam berbagai bentuk dan materi, salah satunya yaitu *cavities*. *Cavities* merupakan rongga udara yang timbul pada beton akibat udara yang terjebak pada proses pengecoran. Umumnya bentuk *cavities* adalah irregular. Dengan menggunakan sinyal GPR, upaya mendeteksi *cavities* tersebut dapat dilakukan. Dalam penelitian ini dilakukan proses rekonstruksi sinyal dari *B-Scan* GPR. Bentuk sinyal yang akan digunakan yaitu *richer wavelet*, karena bentuknya sangat bagus dalam pembentukan data seismik. Proses rekonstruksi sinyal umumnya menggunakan transformasi fourier pada saat mengintegrasikan sinyal *A-Scan*, sehingga relatif rumit dan lama. Dengan menerapkan *Conditional Generative Adversarial Network* (CGAN), data *B-Scan* GPR dapat disintesis menggunakan fungsi Generator dan Diskriminator. Data tersebut dapat digunakan dalam mengidentifikasi dan mengklasifikasi objek pada sinyal GPR, yang fokus penelitian ini berupa bentuk irregular *cavities* pada beton. Dengan penelitian ini, diharapkan terbentuknya suatu metode yang dapat merekonstruksi sinyal *B-Scan* GPR agar lebih sederhana, yang kemudian dapat mendeteksi bentuk irregular *cavities* pada beton.

Index Terms—Irregular, GPR, B-Scan, CGAN.

I. PENDAHULUAN

Ground penetrating radar (GPR) adalah metode geofisika noninvasif untuk mencitrakan diskontinuitas listrik di bawah permukaan yang dangkal. GPR bekerja dengan mengirimkan pulsa elektromagnetik (EM) ke bawah permukaan dan gelombang pantulan direkam oleh antenna di permukaan. Para peneliti

sering menggunakan GPR untuk mempelajari strata bawah permukaan yang dangkal dan untuk mengidentifikasi anomali struktur bawah tanah dalam banyak aplikasi dekat permukaan bumi [1]. *Cavity* merupakan salah satu objek yang dapat diidentifikasi menggunakan GPR.

Cavity pada beton merupakan rongga kosong yang terbentuk di dalam maupun di permukaan beton. Bentuk *cavities* pada beton biasa tidak beraturan (irregular) karena rongga kecil yang saling bergabung menjadi satu. Menurut BPSDM PUPR, kerusakan pada beton akibat rongga udara termasuk dalam kode kerusakan 201 [2]. Kerusakan jenis ini biasa terjadi akibat proses pencampuran yang kurang padat, mengakibatkan beton kehilangan ketahanannya. Oleh karena itu, GPR dapat digunakan untuk mengidentifikasi ukuran dan posisi *cavity* pada bawah permukaan beton.

Untuk memperoleh data bentuk struktur geometri bawah permukaan, data mentahan GPR perlu diproses terlebih dahulu. Terdapat banyak solusi yang telah dilakukan untuk memproses data GPR, baik metode Numerik seperti *Finite-Difference Time-Domain* (FDTD) [3], *Method of Moments* (MoM) [4], dan *Finite Element Time-Domain* (FETD) [5], maupun metode inversi GPR seperti pendekatan *ray-based tomography* [6], *reverse-time migration* (RTM), [7], dan *full-waveform inversion* (FWI) [8]. Namun dari metode tersebut sangat kompleks dalam interpretasinya. Interpretasi data GPR, baik metode numerik maupun inversi GPR, relatif rumit karena adanya variasi dalam respons gelombang elektromagnetik yang dihasilkan oleh berbagai struktur dan bahan bawah permukaan. Dibutuhkan pengetahuan geologi atau pengalaman yang mendalam dalam interpretasi data untuk menghindari

Identify applicable funding agency here. If none, delete this.

kesalahan atau penafsiran yang salah.

Dalam beberapa tahun terakhir, terdapat metode populer berbasis data seperti *neural networks* dalam aplikasi di banyak bidang ilmiah, dengan keberhasilan yang terkemuka terutama dalam bidang visi komputer dan pemrosesan bahasa natural. *Deep neural networks* (DNNs) telah menunjukkan kemampuan luar biasa dalam aplikasi yang berkaitan dengan klasifikasi gambar [9], deteksi objek [10], dan segmentasi semantik (prediksi tingkat piksel) [11] dan sintesis gambar [12]. DNN secara otomatis mempelajari fitur tingkat tinggi melalui data pelatihan dan kemudian dapat memperkirakan pemetaan nonlinear antara data gambar masukan dan berbagai domain data, seperti label, teks, atau gambar lainnya. Oleh karena itu, beberapa metode inversi berbasis *deep learning end-to-end* telah diperkenalkan untuk membalikkan kecepatan atau impedansi dari data seismik [13].

Model generatif adalah bagian dari *neural networks* yang memungkinkan sintesis data yang realistis. *Generative Adversarial Networks* (GANs) merupakan bentuk model generatif yang memiliki fungsi Generator untuk menghasilkan suatu data baru melalui pelatihan (*train*) yang dilakukan dan Diskriminator untuk menentukan apakah data baru tersebut merupakan data palsu atau asli. Pix2pix merupakan salah satu model GAN yang memiliki kemampuan menerjemahkan *image-to-image*. Model ini telah berhasil diterapkan dalam berbagai aplikasi seperti pengolahan citra medis, pemetaan jalan, desain interior, dan seni digital. Oleh karena itu, judul ini diajukan dengan harapan model GAN ini dapat merekonstruksi objek irregular terpendam pada beton berbasis sinyal GPR.

Berdasarkan latar belakang tersebut, maka masalah yang dapat diambil adalah proses rekonstruksi sinyal GPR untuk mendeteksi lokasi *cavities* relatif rumit dan lama. Terdapat banyak solusi yang telah dilakukan untuk memodelkan objek bawah permukaan, namun metode tersebut membutuhkan proses perhitungan yang rumit dan waktu komputasi yang lama. Oleh karena itu, diperlukan suatu metode untuk dapat merekonstruksi objek irregular terpendam pada beton berbasis sinyal GPR.

Tujuan dari penelitian ini adalah membuat suatu metode yang tidak memerlukan proses perhitungan rumit, sehingga dapat merekonstruksi objek irregular terpendam pada beton berbasis sinyal GPR dengan lebih cepat. Dengan dilaksanakannya penelitian ini, diharapkan terbentuknya suatu metode untuk merekonstruksi objek irregular terpendam pada beton berbasis sinyal GPR yang beresolusi tinggi pada beton dengan menggunakan GAN. Selain itu, penelitian ini juga dapat menjadi referensi untuk penelitian selanjutnya terkait rekonstruksi sinyal GPR.

II. PENELITIAN TERDAHULU

Dalam pengerjaan penelitian ini, dibutuhkan referensi yang dapat digunakan untuk membantu penelitian. Referensi penelitian terkait antara lain penelitian [14]- [16].

Penelitian [14] merupakan penelitian terkait penerapan metode GAN untuk mendeteksi objek bawah permukaan

tanah. Dalam penelitiannya, objek yang dideteksi berupa silinder dengan 3 jenis bahan, yaitu besi, plastik, dan beton yang terkubur di bawah permukaan tanah. Penelitian ini juga masih menggunakan metode FDTD dalam modelnya. Hasil penelitian ini menunjukkan bahwa metode GAN dapat digunakan pada data GPR, baik dari data asli maupun data simulasi GPR. Class conditioning dapat diterapkan pada metode GAN dalam menghasilkan training data yang terlabel untuk classifier.

Penelitian [15] merupakan penelitian yang melakukan 2 metode dalam mendeteksi *cavities* pada beton yang masih baru dicetak, yaitu dengan pendekatan *Infrared Thermographic* dan GPR. Penelitian dengan pendekatan GPR bertujuan untuk mengetahui batasan penggunaan GPR pada beton pasca pengecoran. Untuk menghindari kerusakan pada beton pasca pengecoran, sebuah papan triplek digunakan sebagai penampung GPR agar tidak menyentuh beton secara langsung. Hasil penelitian menunjukkan bahwa GPR dapat menjadi metode *non-destructive testing* (NDT) untuk mendeteksi *cavities* dengan ukuran 3.8 cm hingga 10 cm pada saat 3 jam setelah pengecoran beton.

Penelitian [16] merupakan penelitian terkait penggunaan *Conditional Adversarial Networks* (CGAN) dalam mengubah dari suatu gambar ke gambar lain. Penelitian ini mendemonstrasikan penggunaan pix2pix dalam mensintesis foto dari bentuk label kasaran menjadi suatu gambar objek tertentu. Philip Isola beserta timnya menyimpulkan bahwa penggunaan CGAN sangat menjanjikan dalam permasalahan perubahan gambar satu ke gambar lain, terkhususnya yang membutuhkan output terstruktur.

Berdasarkan penelitian referensi tersebut, maka dilakukan penelitian dengan judul Rekonstruksi Objek Irregular Terpendam pada Beton Berbasis Sinyal Ground-Penetrating Radar Menggunakan Generative Adversarial Network". Penelitian ini mengambil ide dari [14] untuk menggunakan metode GAN dalam mendeteksi objek terpendam bawah permukaan. Penelitian ini juga mengambil ide dari [15] dalam mendeteksi *cavities* pada bawah permukaan beton menggunakan GPR. Penelitian ini juga menggunakan metode [16] untuk mengubah dari gambar B-scan menjadi gambar prediksi bentuk dan posisi objek pada bawah permukaan beton.

III. URAIAN PENELITIAN

Penelitian ini dilaksanakan sesuai dengan metodologi yang telah dirancang. Metodologi terbagi menjadi 4 tahap, yaitu pengumpulan data, pembentukan arsitektur GAN, training model, dan evaluasi model. Gambar 1 menunjukkan diagram dari metodologi penelitian.




Fig. 1. Diagram Metodologi Penelitian

A. Dataset GPR

Tahap ini merupakan tahap pengumpulan dataset GPR. Data yang dibutuhkan ada 2 jenis, yaitu data input berupa gambar

B-scan GPR hasil simulasi gprMax dan data output yang diharapkan berupa gambar bentuk geometri dari gambar B-scan GPR. Alur dari proses pengumpulan dataset ditampilkan pada gambar 2.




Fig. 2. Diagram Pengumpulan Dataset GPR

Simulasi menggunakan gprMax untuk menghasilkan file output bentuk geometri simulasi dan file output B-scan GPR dengan menggunakan file input gprMax. Setiap kebutuhan dan cara instalasi gprMax dapat diperoleh di github gprMax. Dalam memasang gprMax, dibutuhkan untuk memasang Python, Miniconda/Anaconda, dan C Compiler yang mendukung OpenMP (Desktop development with C++ pada Visual Studio untuk OS Windows).

Dalam menyusun kode program input GPR, dibutuhkan beberapa parameter penyusun yang perlu diperhatikan. Parameter penyusun tersebut dapat dilihat pada panduan gprMax di website resmi gprMax. Pada penelitian ini, parameter sistem yang dibuat pada dataset GPR dapat dilihat pada tabel I. Contoh penggunaan parameter pada file input juga dapat dilihat pada gambar 3.

TABLE I
PARAMETER INPUT GPRMAX

Parameter	Nilai
Dimensi	0.3 m x 0.3 m x 0.001 m
Jendela Waktu	3 ns
Material	Beton (medium) dan ruang kosong (objek)
Basis Sinyal	Ricker
Arah Laju Sumber Sinyal	0.001 m/step terhadap sumbu-X
Bentuk Objek	Tabung

```

1 #title: B-scan from a void in a concrete
2
3 #domain: 0.3 0.3 0.001
4 #dx_dy_dz: 0.001 0.001 0.001
5 #time_window: 3e-9
6
7 #material: 7.0 0.0 1.0 0.0 concrete
8
9 #waveform: ricker 1 4.5e9 my_ricker
10 #hertzian_dipole: z 0.040 0.240 0 my_ricker
11 #rx: 0.080 0.240 0
12 #src_steps: 0.001 0 0
13 #rx_steps: 0.001 0 0
14
15 #box: 0.0 0.0 0.0 0.3 0.24 0.001 concrete
16 #cylinder: 0.146 0.17 0.0 0.146 0.17 0.001 0.015 free_space
17 #cylinder: 0.16 0.18 0.0 0.16 0.18 0.001 0.017 free_space
18 #cylinder: 0.17 0.16 0.0 0.17 0.16 0.001 0.013 free_space
19 #cylinder: 0.186 0.18 0.0 0.186 0.18 0.001 0.02 free_space
  
```

Fig. 3. Contoh isi file input gprMax

Data input gprMax di atas kemudian disimulasikan dengan 2 tools berbeda untuk menghasilkan file output bentuk geometri simulasi dan file output B-scan GPR. Dari proses simulasi, diperoleh dua buah hasil, yaitu file output bentuk geometri simulasi (.vti) dan file output B-scan GPR (.out). Untuk memperoleh gambar bentuk geometri simulasi, file output bentuk geometri simulasi dijalankan menggunakan aplikasi Paraview. Sedangkan untuk memperoleh gambar bentuk sinyal B-scan GPR, file output B-scan GPR dijalankan menggunakan tools dari gprMax.

Kedua jenis gambar ini kemudian digabung menjadi satu gambar dengan menggunakan library PIL. Kedua gambar akan disusun horizontal, dimana gambar yang kiri berupa gambar B-scan gprMax dan gambar yang kanan berupa gambar bentuk geometrinya. Contoh gabungan gambar ditampilkan pada gambar 4. Gambar hasil gabungan ini yang kemudian menjadi dataset model GAN yang akan dibentuk, yang dalam penelitian ini menggunakan sejumlah 200 data.




Fig. 4. Gambar gabungan bentuk geometri bawah permukaan (kiri) dengan bentuk B-scan GPR hasil simulasi (kanan)

B. Arsitektur GAN

Setelah dataset berhasil dikumpulkan, selanjutnya akan dibentuk model dari GAN. Model GAN yang akan dibentuk menggunakan model Conditional GAN Pix2pix. Arsitektur GAN akan dibagi menjadi 2 bagian, yaitu bagian generator yang berfungsi untuk mensintesis gambar seperti data asli, dan bagian diskriminator yang berfungsi untuk membedakan antara data asli dengan data hasil sintesis. Bentuk arsitektur GAN ditampilkan pada gambar 5.

Pada bagian generator, digunakan arsitektur U-net [17]. Arsitektur ini terdiri dari jaringan encoder yang dilanjut dengan jaringan decoder. Jaringan encoder akan menerapkan proses Convolution >> Batch normalization >> Leaky ReLU. Sedangkan decoder akan menerapkan proses Transposed convolution >> Batch normalization >> Dropout (untuk 3 blok pertama) >> ReLU. Tiap pasang encoder-decoder memiliki skip connection yang berfungsi untuk menangkap setiap informasi tingkat rendah yang dibagikan antara input dan output. Diagram arsitektur Generator dapat dilihat pada gambar 6.

Pada bagian discriminator, digunakan arsitektur Convolutional Patch GAN yang akan mencoba mengklasifikasikan





Fig. 5. Diagram Arsitektur GAN yang Dibentuk



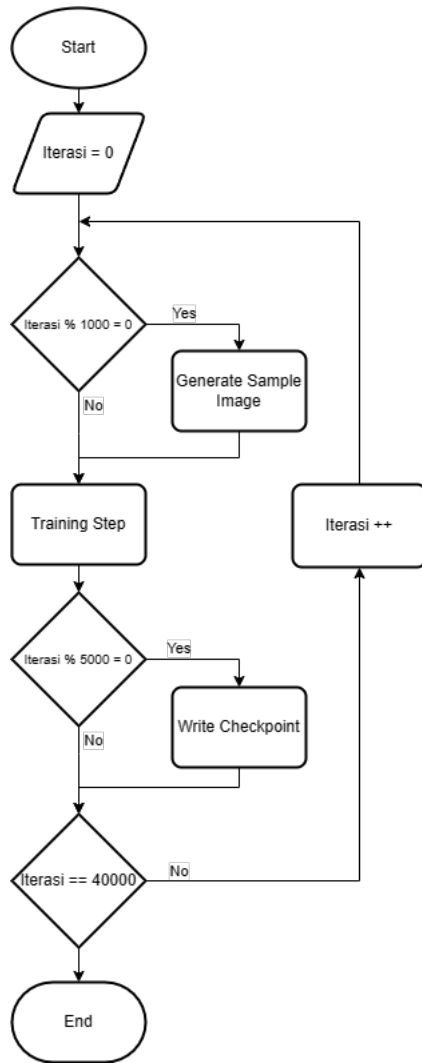


Fig. 8. Diagram Proses Training Model Keseluruhan

Mean Square Error (MSE) dan *Structural Similarity Index* (SSIM). RMS dan MSE umumnya digunakan untuk mengukur kesalahan atau perbedaan antara dua gambar atau sinyal, dengan nilai yang lebih rendah menunjukkan kesamaan yang lebih besar. Sedangkan SSIM memberikan ukuran yang lebih holistik tentang kesamaan struktural antara dua gambar.

Setelah melakukan evaluasi matriks, dilakukan evaluasi visual. Evaluasi visual dilakukan dengan melibatkan penilaian subjektif oleh manusia terhadap kualitas dan kemiripan dua gambar. Dalam membantu proses evaluasi visual, digunakan fungsi *image differencing*. Fungsi *image differencing* melibatkan pengurangan piksel-piksel dari gambar asli dengan gambar sintesis. Hasil pengurangan dapat mengungkapkan informasi penting tentang perubahan struktur, pergeseran objek, atau perubahan lainnya dalam gambar.

IV. HASIL DAN DISKUSI

A. Dataset GPR

Penelitian ini menggunakan dataset GPR buatan sendiri dari hasil simulasi gprMax. Simulasi gprMax dilakukan untuk mendapat 2 jenis data, yaitu data gambar *B-scan* GPR dan data gambar bentuk geometri simulasi. Untuk data gambar *B-scan* membutuhkan waktu sekitar 15-20 menit per simulasi, sedangkan untuk data gambar bentuk geometri simulasi membutuhkan waktu sekitar 5-10 menit per simulasi. Sehingga total waktu yang dibutuhkan untuk mensimulasikan 200 dari data gambar *B-scan* GPR dan data gambar bentuk geometri simulasi serta penggabungan kedua data menjadi satu sekitar 85 jam.

Dari 200 data GPR, 160 data digunakan untuk proses pelatihan model dan 40 data untuk proses evaluasi model. Parameter simulasi pada data ini dibuat acak dengan batasan tertentu untuk data pelatihan dan dibuat menyesuaikan variasi untuk data test. Dataset penelitian divariasikan berdasarkan kategori sebagai berikut.

nolistsep

- 1) Objek berbentuk regular
- 2) Kompleksitas bentuk objek
- 3) Ukuran objek
- 4) Posisi objek di bawah permukaan

Pada kategori variasi objek berbentuk regular, data dibedakan berdasar bentuk reguler objek, yaitu data dengan objek berbentuk lingkaran (silinder tampak depan) dan data dengan objek berbentuk segi empat (silinder tampak samping). Objek hanya terdiri dari 1 objek penyusun, dengan posisi dan ukuran yang dibebaskan, yaitu posisi sekitar 2.5-10 cm di bawah permukaan dan ukuran sekitar 3-10 cm. Contoh data untuk variasi ini dapat dilihat pada gambar 9.




Fig. 9. Data dengan Objek Berbentuk Lingkaran (Kanan) dan Data dengan Objek Berbentuk Segi Empat (Kiri)

Pada kategori variasi kompleksitas bentuk objek, data dibedakan berdasar banyak objek penyusun yang digabung, yaitu data dengan objek sederhana dan data dengan objek kompleks. Objek sederhana memiliki sekitar 3-6 objek penyusun, sedangkan objek kompleks memiliki sekitar 10-15 objek penyusun. Posisi objek dan ukuran objek penyusun kedua data disamakan, yaitu posisi sekitar 6.5 cm di bawah permukaan dan ukuran objek penyusun sekitar 1.5 cm. Contoh data untuk variasi ini dapat dilihat pada gambar 10.

Pada kategori variasi ukuran objek, data dibedakan berdasar besar ukuran objek, yaitu data dengan objek kecil dan data dengan objek besar. Objek kecil memiliki ukuran sekitar 3-4 cm, sedangkan objek besar memiliki ukuran sekitar 5-6 cm. Jumlah objek penyusun serta posisi objek disamakan, yaitu




Fig. 10. Data dengan Objek Berbentuk Sederhana (Kanan) dan Data dengan Objek Berbentuk Kompleks (Kiri)

objek penyusun sejumlah 5 buah dan kedalaman sekitar 4.5 cm. Contoh data untuk variasi ini dapat dilihat pada gambar 11.




Fig. 11. Data dengan Objek Berukuran Besar (Kanan) dan Data dengan Objek Berukuran Kecil (Kiri)

Pada kategori variasi Posisi objek di bawah permukaan, data dibedakan berdasar posisi objek dari permukaan, yaitu data dengan objek dangkal dan data dengan objek dalam. Objek dangkal memiliki posisi sekitar 2.5 cm dari permukaan, sedangkan objek dalam memiliki posisi sekitar 7.5 cm dari permukaan. Ukuran objek dan jumlah objek penyusun disamakan, yaitu ukuran objek sekitar 4.5 cm dan jumlah objek penyusun sejumlah 5 buah. Contoh data untuk variasi ini dapat dilihat pada gambar 12.




Fig. 12. Data dengan Posisi Objek Jauh dari Permukaan (Kanan) dan Data dengan Posisi Objek Dekat dari Permukaan (Kiri)

B. Hasil Pelatihan Model GAN

Proses pelatihan model dilakukan sebanyak 40.000 iterasi. Total waktu yang diperlukan untuk menjalankan keseluruhan proses pelatihan selama 9 jam mulai jam 20.00 WIB hingga pukul 05.00 WIB esok harinya. Selama pelatihan, nilai *total discriminator loss* dan *total generator loss* disimpan ke sebuah *log*. Dengan menggunakan tensorboard, nilai *loss* yang disimpan pada *log* dapat divisualisasikan dalam bentuk grafik.

Gambar 13 menunjukkan grafik *discriminator loss* yang awalnya semakin mengecil kemudian mengalami peningkatan. Hal ini menunjukkan bahwa discriminator awalnya semakin baik dalam mempelajari perbedaan data asli dengan data yang disintesis. Setelah melewati waktu tertentu, discriminator kemudian menjadi semakin sulit dalam mempelajari perbedaan tersebut.

Gambar 14 menunjukkan grafik *generator loss* yang semakin lama semakin mengecil. Hal ini menunjukkan bahwa generator semakin baik dalam mempelajari dan menghasilkan




Fig. 13. Grafik Total Discriminator Loss

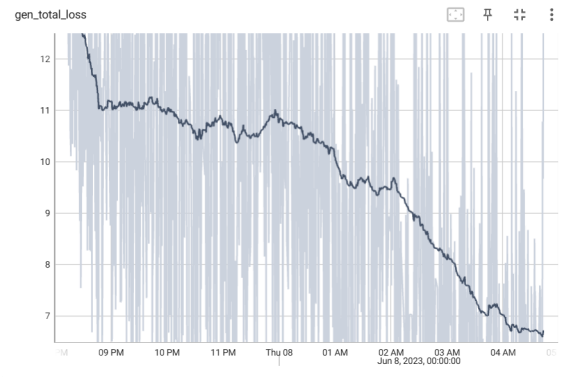


Fig. 14. Grafik Total Generator Loss

data sintesis yang sesuai dengan data asli. Grafik juga menunjukkan penurunan nilai yang lumayan konstan, sehingga dapat dikatakan model generator dilatih secara baik pada proses pelatihan model GAN.

Dalam proses pelatihan model GAN, penting untuk membandingkan nilai atau grafik *generator loss* dan *discriminator loss*. Pada kedua grafik, dapat dilihat bahwa awalnya perubahan kedua nilai *loss* sama-sama menurun, yang menunjukkan proses model dalam mempelajari data berjalan dengan baik. Namun, sekitar pukul 00.00 grafik dari *discriminator loss* menjadi semakin meningkat, sedangkan grafik *generator loss* tetap semakin menurun. Hal ini menunjukkan bahwa pada interval waktu tersebut, discriminator sudah mulai kesulitan dalam membedakan gambar asli dengan gambar palsu, sedangkan generator tetap semakin baik dalam menghasilkan output yang sesuai dengan aslinya.

C. Hasil Evaluasi Output GAN

Data penelitian menggunakan 200 data hasil simulasi *gprMax* untuk gambar *B-scan* GPR beserta bentuk geometri dari simulasi. Dari 200 total data, 40 data digunakan sebagai test data dan dilakukan evaluasi model GAN. Proses evaluasi dilakukan dengan evaluasi matriks kemudian dilanjutkan dengan evaluasi visual. Evaluasi matriks dilakukan dengan menggunakan 3 metode, yaitu metode RMS, MSE, dan SSIM. Untuk nilai hasil RMS dan MSE dikatakan baik jika nilainya semakin

TABLE II
TABEL NILAI RMS, MSE DAN SSIM DARI GAMBAR SINTESIS DENGAN
GAMBAR ASLI SETIAP VARIASI DATA

Variasi Data	RMS		MSE		SSIM	
Bentuk Sederhana	0.256	0.255	0.072	0.073	0.848	0.829
	0.271		0.082		0.811	
	0.265		0.078		0.833	
	0.234		0.063		0.837	
	0.249		0.071		0.816	
Bentuk Kompleks	0.260	0.259	0.075	0.075	0.841	0.832
	0.246		0.068		0.830	
	0.266		0.077		0.832	
	0.260		0.074		0.837	
	0.264		0.080		0.821	
Ukuran Kecil	0.283	0.254	0.091	0.073	0.799	0.829
	0.256		0.073		0.831	
	0.231		0.065		0.829	
	0.246		0.066		0.857	
	0.251		0.069		0.829	
Ukuran Besar	0.267	0.263	0.081	0.078	0.818	0.824
	0.259		0.076		0.817	
	0.236		0.068		0.825	
	0.279		0.084		0.833	
	0.275		0.083		0.826	
Posisi Dekat	0.241	0.239	0.061	0.063	0.842	0.841
	0.231		0.060		0.847	
	0.246		0.069		0.821	
	0.224		0.057		0.847	
	0.252		0.070		0.846	
Posisi Jauh	0.257	0.252	0.076	0.072	0.812	0.829
	0.255		0.073		0.828	
	0.252		0.069		0.851	
	0.263		0.075		0.823	
	0.231		0.065		0.831	
Bentuk Lingkaran	0.206	0.237	0.048	0.064	0.861	0.843
	0.217		0.056		0.844	
	0.264		0.078		0.826	
	0.252		0.071		0.841	
	0.249		0.069		0.843	
Bentuk Segiempat	0.205	0.219	0.053	0.058	0.843	0.838
	0.197		0.047		0.849	
	0.204		0.049		0.857	
	0.257		0.075		0.833	
	0.233		0.065		0.809	
Rata-Rata	0.247		0.070		0.833	

mendekati 0, sedangkan untuk nilai hasil SSIM dikatakan baik jika nilainya semakin mendekati 1. Hasil dari evaluasi matriks untuk keseluruhan data dapat dilihat pada tabel II.

Setelah melakukan evaluasi matriks, dilakukan evaluasi visual. Evaluasi visual dilakukan dengan menggunakan fungsi *image differencing*, yang mengurangi piksel-piksel dari gambar asli dengan gambar sintesis. Hasil evaluasi visual akan ditampilkan dengan gambar, dimana semakin gelap (hitam) warna suatu daerah gambar tertentu, maka semakin identik gambar asli dengan gambar sintesis. Sebaliknya, semakin terang (putih) warna suatu daerah gambar tertentu, maka semakin berbeda gambar asli dengan gambar sintesis.

Berdasarkan keseluruhan hasil evaluasi matriks, diperoleh rata-rata RMS = 0.247, MSE = 0.070, dan SSIM = 0.833. Ketika pelaksanaan penelitian ini, belum ditemukan standar nilai RMS, MSE, dan SSIM yang bersifat universal atau mutlak untuk menentukan apakah kesamaan 2 buah gambar dianggap cukup identik atau belum. Oleh karena itu, nilai rata-rata ini digunakan sebagai standar kemampuan model dalam

menghasilkan data untuk setiap variasinya.

Untuk variasi yang nilai rata-rata RMS dan MSE-nya lebih kecil dari nilai rata-rata RMS dan MSE total, dapat dikatakan perbedaan intensitas piksel antara gambar yang disintesis dengan gambar asli cukup dekat. Variasi tersebut diantaranya variasi posisi objek dekat dari permukaan, bentuk regular lingkaran, dan bentuk regular segi empat. Sebaliknya, untuk variasi yang nilai rata-rata RMS dan MSE-nya lebih besar dari nilai rata-rata RMS dan MSE total, dapat dikatakan perbedaan intensitas piksel antara gambar yang disintesis dengan gambar asli cukup jauh. Variasi tersebut diantaranya variasi bentuk objek sederhana, bentuk objek kompleks, ukuran objek kecil, ukuran objek besar, dan posisi objek jauh dari permukaan.

Untuk variasi yang nilai rata-rata SSIM-nya lebih besar dari nilai rata-rata SSIM total, dapat dikatakan kesamaan struktural antara gambar yang disintesis dengan gambar asli hampir sama. Variasi tersebut diantaranya variasi posisi objek dekat dari permukaan, bentuk regular lingkaran, dan bentuk regular segi empat. Sebaliknya, untuk variasi yang nilai rata-rata SSIM-nya lebih kecil dari nilai rata-rata SSIM total, dapat dikatakan kesamaan struktural antara gambar yang disintesis dengan gambar asli cukup jauh. Variasi tersebut diantaranya variasi bentuk objek sederhana, bentuk objek kompleks, ukuran objek kecil, ukuran objek besar, dan posisi objek jauh dari permukaan.

Setelah melakukan evaluasi matriks, dilakukan evaluasi visual. Evaluasi visual dilakukan dengan menggunakan fungsi *image differencing*, yang mengurangi piksel-piksel dari gambar asli dengan gambar sintesis. Hasil evaluasi visual akan ditampilkan dengan gambar, dimana semakin gelap (hitam) warna suatu daerah gambar tertentu, maka semakin identik gambar asli dengan gambar sintesis. Sebaliknya, semakin terang (putih) warna suatu daerah gambar tertentu, maka semakin berbeda gambar asli dengan gambar sintesis.

Pada variasi kompleksitas bentuk objek, terlihat untuk objek berbentuk sederhana memiliki rata-rata nilai evaluasi matriks yang lebih baik dari objek berbentuk kompleks. Perbedaan rata-rata evaluasi matriks terlihat cukup dekat di antara kedua variasi data. Nilai rata-rata RMS dan MSE data objek sederhana lebih kecil dari nilai rata-rata RMS dan MSE data objek kompleks. Namun, nilai rata-rata SSIM data objek sederhana lebih kecil dari nilai rata-rata SSIM data objek kompleks.




Fig. 15. Evaluasi Visual Data Variasi Bentuk Sederhana

Untuk variasi data dengan objek sederhana akan diambil data pertama karena memiliki nilai evaluasi matriks yang lebih mendekati rata-rata variasi bentuk objek dari data lain. Evaluasi visual dari data dapat dilihat dari gambar 15. Pada gambar evaluasi visual dapat dilihat bahwa irisan dari objek sintesis dengan objek asli cukup luas sehingga memiliki area error yang cukup sempit. Hal ini menunjukkan bahwa output model sudah bisa menunjukkan posisi dan ukuran objek, namun masih belum bisa menunjukkan bentuk objek.




Fig. 16. Evaluasi Visual Data Variasi Bentuk Kompleks

Untuk variasi data dengan objek kompleks akan diambil data pertama karena memiliki nilai evaluasi matriks yang lebih mendekati rata-rata variasi bentuk objek dari data lain. Evaluasi visual dari data dapat dilihat dari gambar 16. Pada gambar evaluasi visual dapat dilihat bahwa irisan dari gambar sintesis dengan gambar asli hampir merupakan gambar sintesis sepenuhnya. Hal ini menunjukkan bahwa output model sudah bisa menunjukkan posisi objek, namun masih belum bisa menunjukkan bentuk dan ukuran objek.

Pada variasi ukuran objek, terlihat untuk objek berukuran kecil memiliki rata-rata nilai evaluasi matriks yang lebih baik dari objek berukuran besar. Perbedaan rata-rata evaluasi matriks terlihat cukup jauh di antara kedua variasi data. Nilai rata-rata RMS dan MSE data objek berukuran kecil lebih kecil dari nilai rata-rata RMS dan MSE data objek berukuran besar. Namun, nilai rata-rata SSIM data objek berukuran kecil lebih besar dari nilai rata-rata SSIM data objek berukuran besar.




Fig. 17. Evaluasi Visual Data Variasi Ukuran Kecil

Untuk variasi data dengan objek berukuran kecil akan di-

ambil data kelima karena memiliki nilai evaluasi matriks yang lebih mendekati rata-rata variasi ukuran objek dari data lain. Evaluasi visual dari data dapat dilihat dari gambar 17. Pada gambar evaluasi visual dapat dilihat bahwa irisan dari objek sintesis dengan objek asli cukup sedikit sehingga memiliki area error yang cukup luas. Hal ini menunjukkan bahwa output model hampir bisa menunjukkan posisi dan ukuran objek, namun masih belum bisa menunjukkan bentuk objek.




Fig. 18. Evaluasi Visual Data Variasi Ukuran Besar

Untuk variasi data dengan objek berukuran besar akan diambil data pertama karena memiliki nilai evaluasi matriks yang lebih mendekati rata-rata variasi ukuran objek dari data lain. Evaluasi visual dari data dapat dilihat dari gambar 18. Pada gambar evaluasi visual dapat dilihat bahwa irisan dari objek sintesis dengan objek asli cukup sempit sehingga memiliki area error yang cukup luas. Hal ini menunjukkan bahwa output model hampir bisa menunjukkan posisi objek, namun masih belum bisa menunjukkan bentuk dan ukuran objek.

Pada variasi posisi objek, terlihat untuk objek dengan posisi dekat dengan permukaan memiliki rata-rata nilai evaluasi matriks yang lebih baik dari objek dengan posisi jauh dengan permukaan. Perbedaan rata-rata evaluasi matriks terlihat cukup jauh di antara kedua variasi data. Nilai rata-rata RMS dan MSE data posisi objek dekat dari permukaan lebih kecil dari nilai rata-rata RMS dan MSE data posisi objek jauh dari permukaan. Namun, nilai rata-rata SSIM data posisi objek dekat dari permukaan lebih besar dari nilai rata-rata SSIM data posisi objek jauh dari permukaan.




Fig. 19. Evaluasi Visual Data Variasi Posisi Dekat dengan Permukaan

Untuk variasi data dengan posisi objek dekat dari permukaan akan diambil data pertama karena memiliki nilai evaluasi matriks yang lebih mendekati rata-rata variasi posisi objek dari data lain. Evaluasi visual dari data dapat dilihat dari gambar 19. Pada gambar evaluasi visual dapat dilihat bahwa irisan dari objek sintesis dengan objek asli cukup sedikit sehingga memiliki area error yang cukup luas. Hal ini menunjukkan bahwa output model hampir bisa menunjukkan posisi objek, namun masih belum bisa menunjukkan bentuk dan ukuran objek.




Fig. 20. Evaluasi Visual Data Variasi Posisi Jauh dengan Permukaan

Untuk variasi data dengan posisi objek jauh dari permukaan akan diambil data kedua karena memiliki nilai evaluasi matriks yang lebih mendekati rata-rata variasi posisi objek dari data lain. Evaluasi visual dari data dapat dilihat dari gambar 20. Pada gambar evaluasi visual dapat dilihat bahwa irisan dari objek sintesis dengan objek asli cukup sedikit sehingga memiliki area error yang cukup luas. Hal ini menunjukkan bahwa output model hampir bisa menunjukkan posisi objek, namun masih belum bisa menunjukkan bentuk dan ukuran objek.

Pada variasi bentuk regular objek, terlihat untuk objek berbentuk lingkaran memiliki rata-rata nilai evaluasi matriks yang lebih buruk dari objek berbentuk segi empat. Perbedaan rata-rata evaluasi matriks terlihat cukup jauh di antara kedua variasi data. Nilai rata-rata RMS dan MSE data objek berbentuk lingkaran lebih besar dari nilai rata-rata RMS dan MSE data objek berbentuk segi empat. Namun, nilai rata-rata SSIM data objek berbentuk lingkaran lebih besar dari nilai rata-rata SSIM data objek berbentuk segi empat.

Untuk variasi data dengan bentuk lingkaran akan diambil data kelima karena memiliki nilai evaluasi matriks yang lebih mendekati rata-rata variasi bentuk regular objek dari data lain. Evaluasi visual dari data dapat dilihat dari gambar 21. Pada gambar evaluasi visual dapat dilihat bahwa irisan dari objek sintesis dengan objek asli cukup sedikit sehingga memiliki area error yang cukup luas. Hal ini menunjukkan bahwa output model hampir bisa menunjukkan posisi objek, namun masih belum bisa menunjukkan bentuk dan ukuran objek.

Untuk variasi data dengan bentuk segi empat akan diambil data pertama karena memiliki nilai evaluasi matriks yang lebih mendekati rata-rata variasi bentuk regular objek dari data lain. Evaluasi visual dari data dapat dilihat dari gambar 22. Pada




Fig. 21. Evaluasi Visual Data Variasi Bentuk Regular Lingkaran

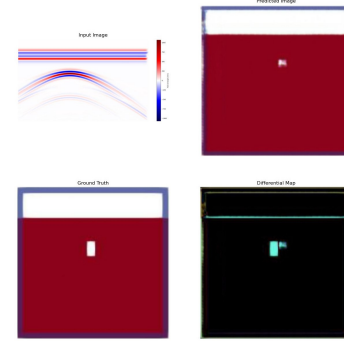


Fig. 22. Evaluasi Visual Data Variasi Bentuk Regular Segi Empat

gambar evaluasi visual dapat dilihat bahwa irisan dari objek sintesis dengan objek asli cukup sedikit sehingga memiliki area error yang cukup luas. Hal ini menunjukkan bahwa output model hampir bisa menunjukkan posisi objek, namun masih belum bisa menunjukkan bentuk dan ukuran objek.

V. KESIMPULAN DAN SARAN

Hasil penelitian dari penggunaan model GAN untuk merekonstruksi sinyal B-scan GPR pada objek berbentuk irregular menunjukkan bahwa selama proses pelatihan model GAN, grafik Total Generator Loss mengalami penurunan nilai dari awal hingga akhir, sedangkan grafik Total Discriminator Loss mengalami penurunan nilai di awal, kemudian mengalami kenaikan nilai di akhir. Hal ini menunjukkan bahwa Generator semakin baik dalam menghasilkan gambar yang diinginkan. Namun, Discriminator awalnya semakin baik dalam membedakan data asli dengan data palsu, namun pada akhir pelatihan semakin kesulitan dalam membedakannya. Berdasarkan hasil evaluasi matriks dari 40 test data GPR ($RMS_{rerata} = 0.247$, $MSE_{rerata} = 0.070$, $SSIM_{rerata} = 0.833$), model GAN bekerja lebih baik dalam mensintesis gambar struktur bawah permukaan untuk objek dengan posisi dekat dengan permukaan (RMS = 0.239, MSE = 0.63, SSIM = 0.841), berbentuk lingkaran (RMS = 0.237, MSE = 0.064, SSIM = 0.843) dan berbentuk segi empat (RMS = 0.219, MSE = 0.058, SSIM = 0.838). Namun, berdasarkan hasil evaluasi visual, output model cukup mampu menunjukkan posisi objek, dan masih belum bisa menunjukkan bentuk dan ukuran objek un-

tuk setiap variasinya. Untuk pengembangan lebih lanjut pada penelitian tugas akhir ini, penulis menyarankan untuk dapat memperbanyak data train untuk variasi bentuk dan ukuran benda guna memaksimalkan hasil prediksi gambar. Jenis objek dan media perambatan baru untuk sinyal GPR hasil simulasi gprMax juga dapat ditambahkan. Penelitian lebih lanjut juga dapat dikembangkan untuk bentuk sinyal GPR lainnya, yaitu A-scan maupun C-scan.

VI. LAMPIRAN

Segala keperluan yang digunakan dalam pembuatan penelitian ini disimpan pada github yang dapat diakses melalui link : MehhTerserah/TA-072-19-0040 (github.com)

VII. UCAPAN TERIMA KASIH

Penulis J.P.S mengucapkan terima kasih kepada keluarga penulis yang membantu penulis secara spiritual dan material dalam penyusunan artikel ini, bapak Dr. Supeno Mardi Susiki Nugroho, ST., MT. selaku Kepala Departemen Teknik Komputer, Fakultas Teknologi Elektro dan Informatika Cerdas (FTEIC), Institut Teknologi Sepuluh Nopember, bapak Dion Hayu Fandiantoro, S.T., M.Eng. selaku dosen pembimbing I dan bapak Arief Kurniawan, S.T, M.T. selaku dosen pembimbing II yang selalu memberikan arahan selama mengerjakan penelitian tugas akhir ini, Bapak-ibu dosen pengajar Departemen Teknik Komputer, atas pengajaran, bimbingan, serta perhatian yang diberikan kepada penulis selama ini.

REFERENCES

- [1] Neal, A. (2004). Ground-penetrating radar and its use in sedimentology: Principles, problems and progress. *Earth-Science Reviews*, 66(3), 261–330. <https://doi.org/https://doi.org/10.1016/j.earscirev.2004.01.004>
- [2] PUPR, B. (2015). Diklat pemeliharaan jembatan ii : Modul 2 perbaikan kerusakan berdasarkan bahan. [https://simantu.pu.go.id/epel/edok/2d370Modul 2 - Perbaikan Kerusakan Berdasarkan Bahan.pdf](https://simantu.pu.go.id/epel/edok/2d370Modul%202%20-%20Perbaikan%20Kerusakan%20Berdasarkan%20Bahan.pdf)
- [3] Gurel, L., and Oguz, U. (2000). Three-dimensional ftdt modeling of a ground-penetrating radar. *IEEE Transactions on Geoscience and Remote Sensing*, 38(4), 1513–1521. <https://doi.org/10.1109/36.851951>
- [4] van den Bosch, I., Lambot, S., Huynen, I., Marc, A., and Druyts, P. (2006). Accurate and efficient modeling of monostatic gpr signal of dielectric targets buried in stratified media. *Journal of Electromagnetic Waves and Applications*, 20, 283–290. <https://doi.org/10.1163/156939306775701704>
- [5] Liu, H., Xing, B., Wang, H., Cui, J., and Spencer, B. F. (2019). Simulation of ground penetrating radar on dispersive media by a finite element time domain algorithm. *Journal of Applied Geophysics*, 170, 103821. <https://doi.org/https://doi.org/10.1016/j.jappgeo.2019.103821>
- [6] Irving, J., Knoll, M., and Knight, R. (2007). Improving crosshole radar velocity tomograms: A new approach to incorporating high-angle traveltime data. *Geophysics*, 72, J31–J41. <https://doi.org/10.1190/1.2742813>
- [7] Liu, S., Lei, L., Fu, L., and Wu, J. (2014). Application of pre-stack reverse time migration based on fwi velocity estimation to ground penetrating radar data. *Journal of Applied Geophysics*, 1–7.
- [8] Kruk, J., Liu, T., Mozaffari, A., Gueting, N., Klotzsche, A., Vereecken, H., Warren, C., and Giannopoulos, A. (2018). Gpr full-waveform inversion, recent developments, and future opportunities, 1–6. <https://doi.org/10.1109/ICGPR.2018.8441667>
- [9] Ishitsuka, K., Iso, S., Onishi, K., and Matsuoka, T. (2018). Object detection in ground-penetrating radar images using a deep convolutional neural network and image set preparation by migration. *International Journal of Geophysics*, 2018, 1–8. <https://doi.org/10.1155/2018/9365184>
- [10] Ren, S., He, K., Girshick, R., and Sun, J. (2017). Faster r-cnn: Towards real-time object detection with region proposal networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(6), 1137–1149. <https://doi.org/10.1109/TPAMI.2016.2577031>
- [11] Jiang, P., Gu, F., Tu, C., and Chen, B. (2018, May). Difnet: Semantic segmentation by diffusion networks.
- [12] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. (2014). Generative adversarial networks. *Advances in Neural Information Processing Systems*, 3. <https://doi.org/10.1145/3422622>
- [13] Liu, B., Ren, Y., Liu, H., Xu, H., Wang, Z., Cohn, A., and Jiang, P. (2021). Gprinvnet: Deep learning-based ground-penetrating radar data inversion for tunnel linings. *IEEE Transactions on Geoscience and Remote Sensing*, PP, 1–21. <https://doi.org/10.1109/TGRS.2020.3046454>
- [14] Rice, W. B. D. (2019). Applying generative adversarial networks to intelligent subsurface imaging and identification. *ArXiv, abs/1905.13321*
- [15] Shen, Z., Erdogmus, E., Morcou, G., Cheng, C., Shang, Z., McCabe, T., and Kods, A. (2020). Early detection of near-surface void defects in concrete pavement using drone based thermography and gpr methods.
- [16] Isola, P., Zhu, J.-Y., Zhou, T., and Efros, A. (2017). Image-to-image translation with conditional adversarial networks, 5967–5976. <https://doi.org/10.1109/CVPR.2017.632>
- [17] Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. *LNCS*, 9351, 234–241. https://doi.org/10.1007/978-3-319-24574-4_28